


Lecture 29. Singular value decomposition. ★ Super Important

1. Overview

SVD, 任意矩阵都可以分解为 $A = U \Sigma V^T$, U 为 Orthogonal Matrix 正交矩阵, Σ 是对角矩阵, V 是正交矩阵。

如果 A 正定, 它的 SVD 就是 $A = Q \Lambda Q^T$, 一个 Q 就满足, 这也是 正定最大的优点。对于可对角化矩阵, $A = S \Lambda S^{-1}$, 但特征向量矩阵 S 并不是正交矩阵, 而 SVD 中 U 和 V 是正交矩阵。

2. 定义



矩阵 A 可以理解一种线性变换, 行空间中一个向量 v_i 变到列空间中 $u_i = Av_i$ 。奇异值分解就是在行空间中找到一组正交基, 将其通过矩阵 A 线性变换生成列空间中的一组正交基:

找到行空间中的一组正交基很容易, Gram-Schmidt 正交化即可。但随便一组正交基经过 A 变换后不一定正交, 因此要满足此要求的行空间的正交基非常特殊。

$$Av_i = \sigma_i u_i, \sigma_i \text{ 是使它归一化的因子。} \sigma_i > 0$$

设在行空间中找到一组特殊正交基:

$$\begin{aligned} A[v_1 \ v_2 \ \dots \ v_r] &= [\sigma_1 u_1 \ \sigma_2 u_2 \ \dots \ \sigma_r u_r] \\ &= [u_1 \ u_2 \ \dots \ u_r] \begin{bmatrix} \sigma_1 & & & \\ & \sigma_2 & & \\ & & \ddots & \\ & & & \sigma_r \end{bmatrix} \end{aligned} \quad \left. \right\} AV = U\Sigma$$

如果加入 Null Space,

$$A[v_1 \ v_2 \ \dots \ v_r \ v_{r+1} \ \dots \ v_n] = [\sigma_1 u_1 \ \sigma_2 u_2 \ \dots \ \sigma_r u_r \ \sigma_{r+1} u_{r+1} \ \dots \ \sigma_n u_n]$$

$$= [u_1 \ u_2 \ \dots \ u_r \ u_{r+1} \ \dots \ u_n] \begin{bmatrix} \sigma_1 & & & & \\ & \sigma_2 & & & \\ & & \ddots & & \\ & & & \sigma_r & \\ & & & & 0 \end{bmatrix}$$

$$\text{现在 } AV = U\Sigma$$

$$\text{已知 } AV = U\Sigma$$

$$\begin{aligned} \text{例1. } A &= U\Sigma V^{-1} \\ &= U\Sigma V^T \quad \Rightarrow \\ A^T &= V\Sigma U^T \end{aligned}$$

我们想求 U 和 V , 但无法同时求, 于是,

$$\begin{aligned} A^T A &= V\Sigma V^T U\Sigma U^T \\ &= V \begin{bmatrix} \sigma_1^2 & & \\ & \sigma_2^2 & \\ & & \ddots & \sigma_r^2 \end{bmatrix} V^T \end{aligned}$$

因为 $A^T A$ 在 A 为满秩时正定, 上式其实就是 $A^T A$ 的正交分解.

V 是 $A^T A$ 的 eigen vector, σ^2 是 A 的 eigen value.

用同样的办法找 U :

U 是 AA^T 的 eigen vector, eigen value 不变。

$$\text{例1. } A = \begin{bmatrix} 4 & 4 \\ -3 & 3 \end{bmatrix}, \text{ 求 SVD.}$$

$$(25 - \lambda)^2 - 49 = 0$$

$$\text{求 } V. \quad A^T A = \begin{bmatrix} 4 & -3 \\ 4 & 3 \end{bmatrix} \begin{bmatrix} 4 & 4 \\ -3 & 3 \end{bmatrix} = \begin{bmatrix} 25 & 7 \\ 7 & 25 \end{bmatrix}, \quad \begin{vmatrix} 25 - \lambda & 7 \\ 7 & 25 - \lambda \end{vmatrix} = 0$$

$$\begin{aligned} \lambda_1 &= \sigma_1^2 = 32 \\ \lambda_2 &= \sigma_2^2 = 18 \end{aligned} \quad X_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad X_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix} \quad X_1, X_2 \perp \text{且交}, \text{ 因为 } A^T \text{ 为对称.}$$

$$\text{标准化后: } V_1 = \begin{bmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{bmatrix}, \quad V_2 = \begin{bmatrix} 1/\sqrt{2} \\ -1/\sqrt{2} \end{bmatrix}, \quad \sigma_1^2 = 32, \quad \sigma_2^2 = 18.$$

$$V = \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ 1/\sqrt{2} & -1/\sqrt{2} \end{bmatrix}$$

$$\text{求 } U. \quad AA^T = \begin{bmatrix} 32 & 0 \\ 0 & 18 \end{bmatrix}, \quad X_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad X_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix},$$

$$\text{标准化后, } U_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad U_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \quad \sigma_1^2 = 32, \quad \sigma_2^2 = 18.$$

$$U = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

但是

$$U\Sigma V^T = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \sqrt{32} & 0 \\ 0 & \sqrt{18} \end{bmatrix} \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ 1/\sqrt{2} & -1/\sqrt{2} \end{bmatrix} = \begin{bmatrix} 4 & 4 \\ 3 & -3 \end{bmatrix} \neq A$$

因为在计算 AA^T 的 eigen vector 时, 其方向正反皆可, 无法确定其符号。但在 $A = U\Sigma V^T$ 中, V 确定后, U 的符号也确定了, 所以为避免此问题, 可以比 V 直接代入 $AV = U\Sigma$ 来计算 U .

例2. $A = \begin{bmatrix} 4 & 3 \\ 8 & 6 \end{bmatrix}$, 求 SVD.

A 是 Singular Matrix, rank = 1, 行空间 / 列空间是 1 维的。

可以确定 $V_1 = \begin{bmatrix} 0.8 \\ 0.6 \end{bmatrix}$, $V_2 = \begin{bmatrix} 0.6 \\ -0.8 \end{bmatrix}$, $U_1 = \frac{1}{\sqrt{5}} \begin{bmatrix} 1 \\ 2 \end{bmatrix}$, $U_2 = \frac{1}{\sqrt{5}} \begin{bmatrix} 2 \\ -1 \end{bmatrix}$

$$A^T A = \begin{bmatrix} 80 & 60 \\ 60 & 45 \end{bmatrix}, \sigma_1^2 = 125, \sigma_2^2 = 0$$

$$\Rightarrow A = \frac{1}{\sqrt{5}} \begin{bmatrix} 1 & 2 \\ 2 & -1 \end{bmatrix} \begin{bmatrix} \sqrt{125} & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 0.8 & 0.6 \\ 0.6 & -0.8 \end{bmatrix}$$

做 SVD 就是在矩阵的四个子空间中寻找合适的基：

V_1, V_2, \dots, V_r 为行空间的标准正交基。

$V_{r+1}, V_{r+2}, \dots, V_n$ 为 $N(A)$ 的标准正交基。

U_1, U_2, \dots, U_r 为列空间的标准正交基。

$U_{r+1}, U_{r+2}, \dots, U_n$ 为 $N(A^T)$ 的标准正交基。

SVD 的应用：因为实际问题中 A 通常不是满秩的，因此 $A^T A$ 不可逆，无法分解为 $Q A Q^T$ 。另外， $A^T A$ 计算量太大，用 SVD 会降低计算量。

$$A = U \sum V^T$$